

THE BLACK BOX OF THE BLACK BOXES

UMA INTRODUÇÃO A AUTOML COM PYTHON

JOSE ANDRADE

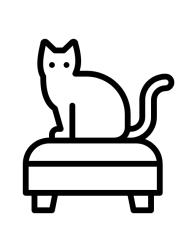
[~] \$ whoami

```
"Name": "José Andrade",
"City": Natal,
"Job": "Data Scientist",
"Company": "Data Science Brigade",
"Github": http://github.com/andradejunior
"Linkedin": http://linkedin.com/in/andrade-junior,
"Twitter": @4ndradejr,
"Telegram": @andradejunior
```



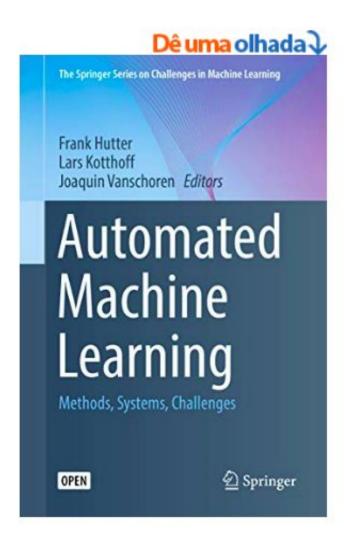








// Dica de leitura



Automated Machine Learning: Methods, Systems, Challenges (The Springer Series on Challenges in Machine Learning) (English Edition) eBook Kindle

por Frank Hutter (Autor, Editor), Lars Kotthoff (Autor, Editor), Joaquin Vanschoren (Autor, Editor) Formato: eBook Kindle

★★★★ × 5 classificações
 Ver todos os 2 formatos e edições
 Kindle R\$0,00
 Leia com nossos apps gratuitos
 Capa dura R\$498,99 ✓ prime
 2 Novo a partir de R\$498,99

This open access book presents the first comprehensive overview of general methods in Automated Machine Learning (AutoML), collects descriptions of existing systems based on these methods, and discusses the first series of international challenges of AutoML systems. The recent success of commercial ML applications and the rapid growth of the field has created a high demand for off-the-shelf ML methods that can be used easily and without expert knowledge. However, many of the recent machine learning successes crucially rely on human experts, who manually select appropriate ML architectures (deep learning architectures or more traditional ML workflows) and their hyperparameters. To overcome this problem, the field of AutoML targets a progressive automation of machine learning, based on principles from optimization and machine learning itself. This book serves as a point of entry into this quickly-developing field for researchers and advanced students alike, as well as providing a reference for practitioners aiming to use AutoML in their work.

https://www.amazon.com.br/gp/product/B07S3MLGFW

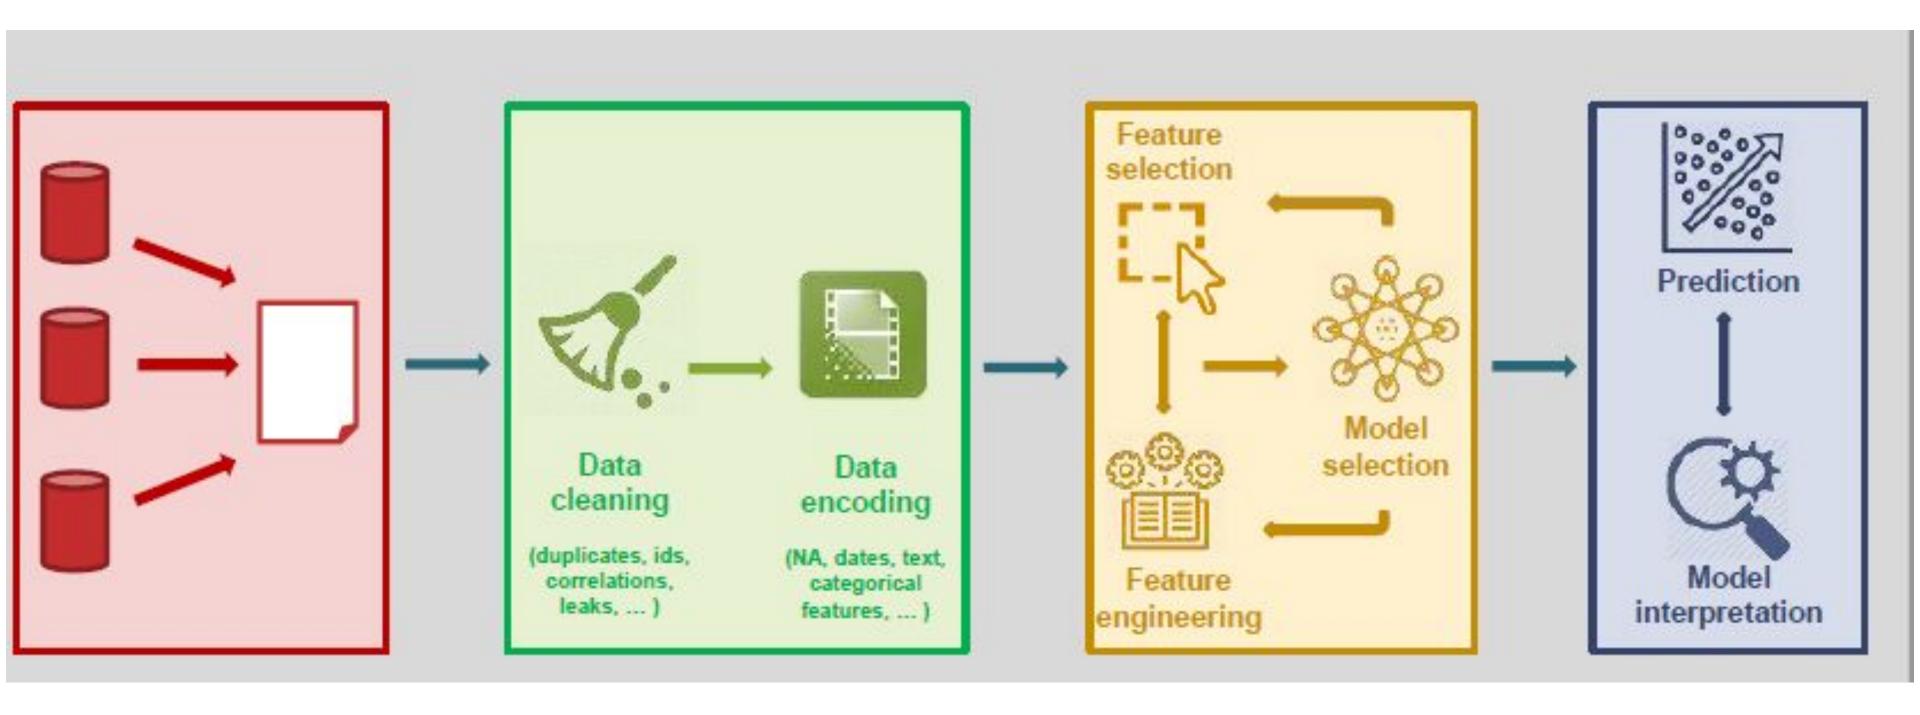
https://link.springer.com/book/10.1007%2F978-3-030-05318-5

- 1 Motivação
- 2 Métodos de AutoML
- 3 Sistemas de AutoML
- 4 Conclusões



Motivação

// Motivação





 Alta demanda na área de IA e baixa oferta de mão de obra especializada.



 Alta demanda na área de IA e baixa oferta de mão de obra especializada. Expectativa: 58 milhões de empregos em IA até 2022, de acordo com o <u>Fórum Econômico Mundial</u>.

https://www.forbes.com/sites/amitchowdhry/2018/09/18/artificial-intelligence-to-create-58-million-new-jobs-by-2022-says-report/#c07b70c4d4ba



 Alta demanda na área de IA e baixa oferta de mão de obra especializada. Expectativa: 58 milhões de empregos em IA até 2022, de acordo com o <u>Fórum Econômico Mundial</u>.

https://www.forbes.com/sites/amitchowdhry/2018/09/18/artificial-intelligence-to-create-58-million-new-iobs-by-2022-says-report/#c07b70c4d4ba

Estima-se que em 2017 havia 300 mil engenheiros de IA no mundo, enquanto milhões são necessário de acordo com o Instituto de Pesquisa de Tencent.

https://www.theverge.com/2017/12/5/16737224/global-ai-talent-shortfall-tencent-report



 Alta demanda na área de IA e baixa oferta de mão de obra especializada.

Solução

AutoML

- Engenharia de características
- Seleção de algoritmos
- Otimização de hiperparâmetros





DEFINIÇÃO

Processo de automatizar o passo a passo da aplicação de aprendizado de máquina a problemas do mundo real.

Métodos

// Métodos de AutoML

Hyperparameter Optimization

CASH: Combined

Algorithm Selection and

Hyperparameter

Optimization

// Métodos de AutoML

Hyperparameter Optimization

CASH: Combined
 Algorithm Selection and
 Hyperparameter
 Optimization

Meta-Learning

Aprender a aprender

// Métodos de AutoML

Hyperparameter Optimization

CASH: Combined
 Algorithm Selection and
 Hyperparameter
 Optimization

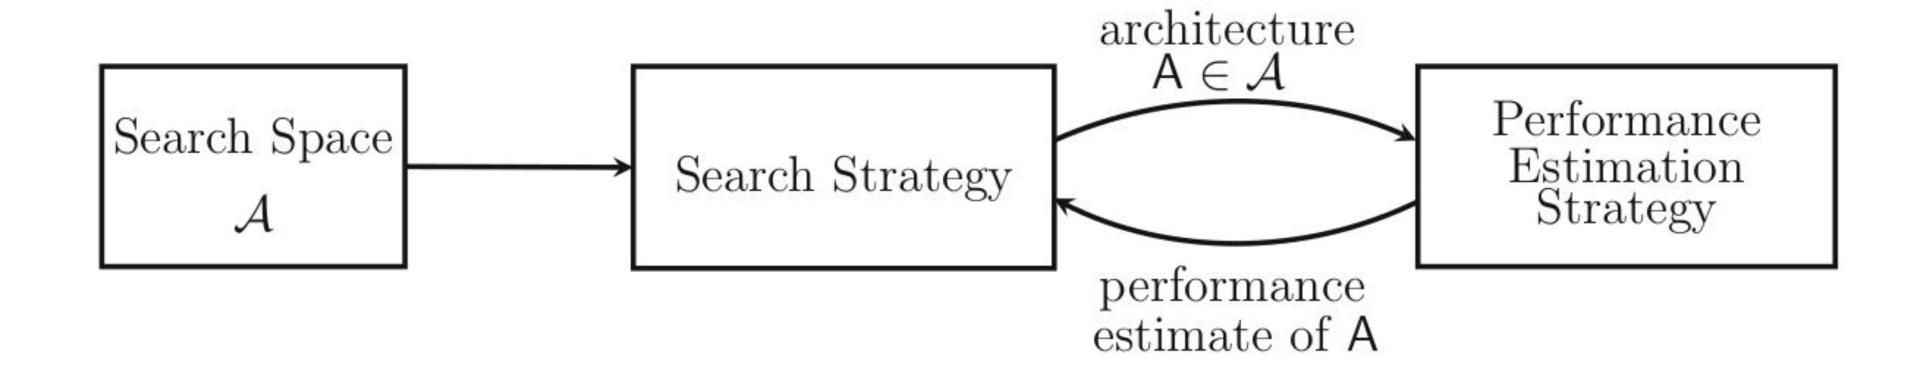
Meta-Learning

Aprender a aprender

Neural Architecture Search

- Search space
- Search strategy
- Performance estimation strategy

// Neural Architecture Search



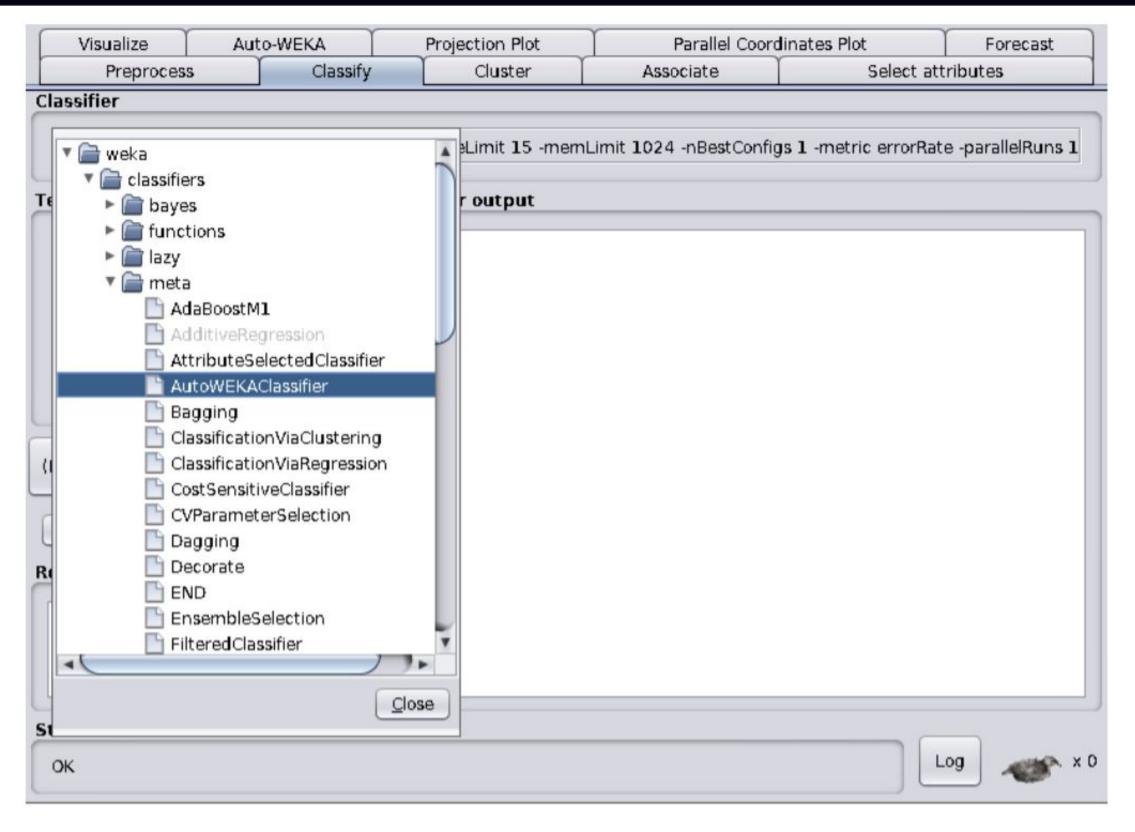
3

Sistemas

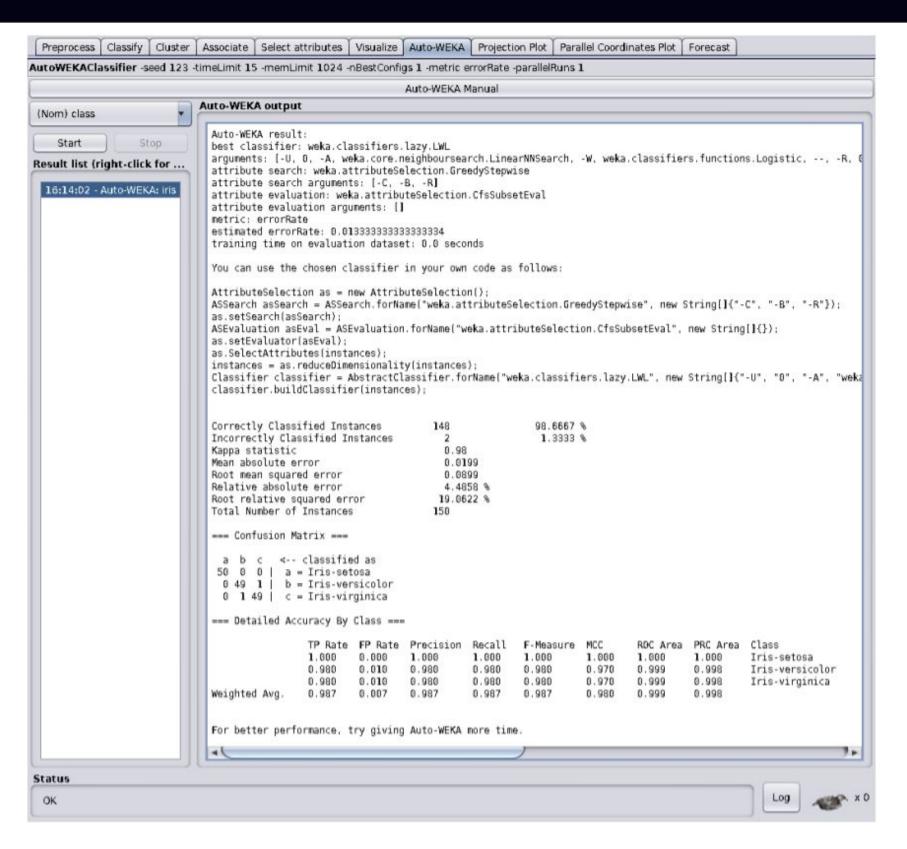
// Auto-WEKA



// Auto-WEKA



// Auto-WEKA



```
from hpsklearn import HyperoptEstimator
estim = HyperoptEstimator()
estim.fit(X_train, y_train)
prediction = estim.predict(X_test)
score = estim.score(X_test, y_test)
model = estim.best_model()
```

- Domínio de busca
- Função objetivo
- Algoritmo de otimização

- Domínio de busca
- Função objetivo
- Algoritmo de otimização

```
space = hp.choice('my_conditional',
[
    ('case 1', 1 + hp.lognormal('c1', 0, 1)),
    ('case 2', hp.uniform('c2', -10, 10))
    ('case 3', hp.choice('c3', ['a', 'b', 'c']))
])
```



- Domínio de busca
- accuracy, F1-score, etc
- Função objetivo Algoritmo de otimização

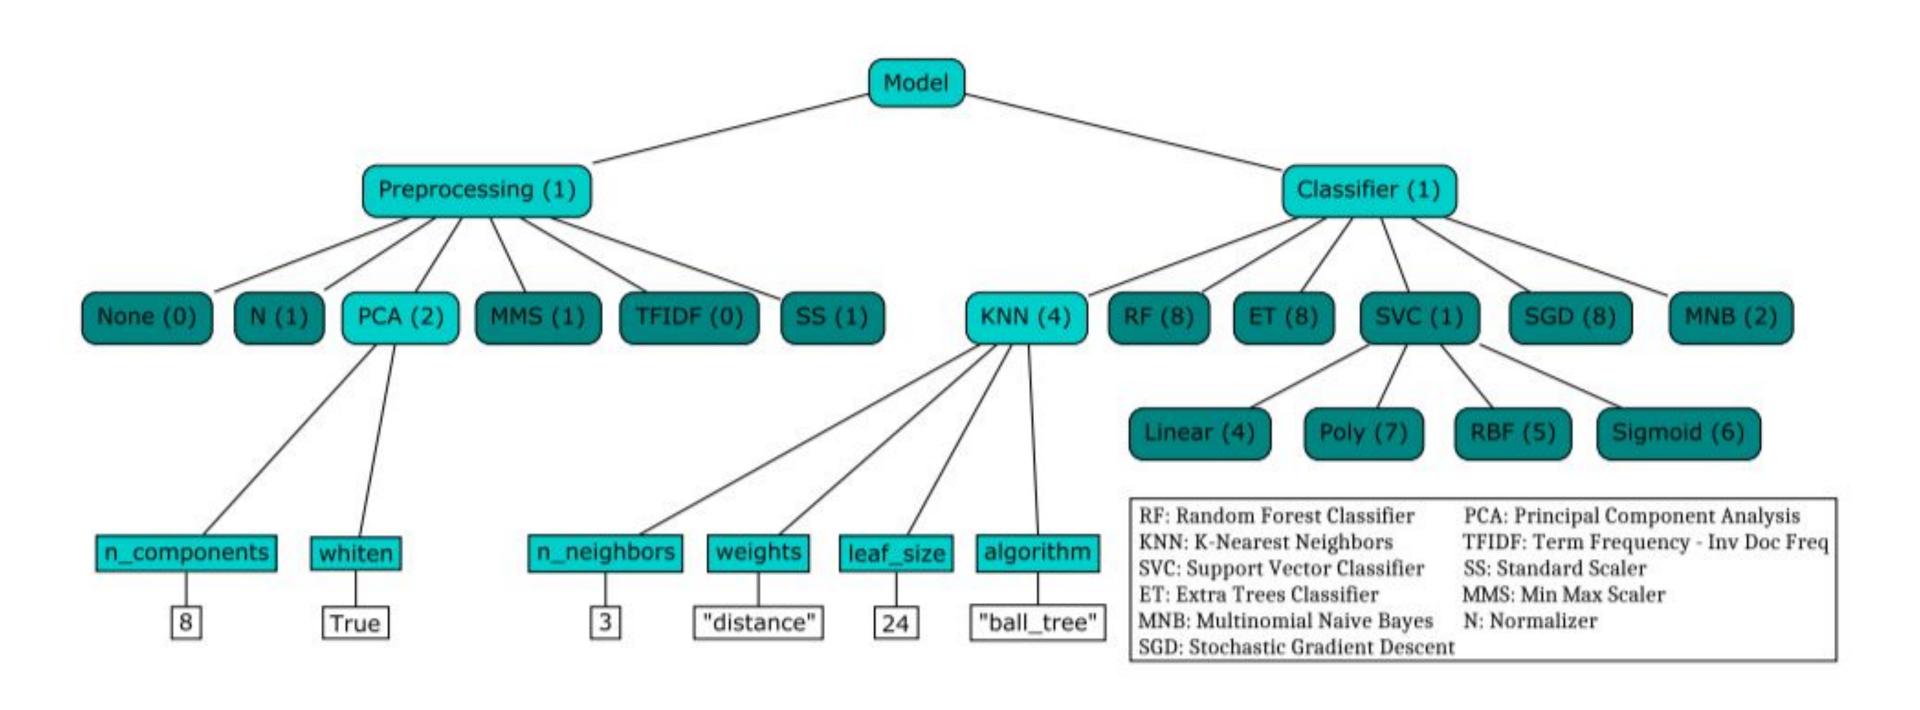
- Domínio de busca
- Função objetivo
- Algoritmo de otimização
 - Random Search
 - Tree of ParzenEstimators(TPE)
 - Annealing
 - Tree
 - Gaussian Tree Process

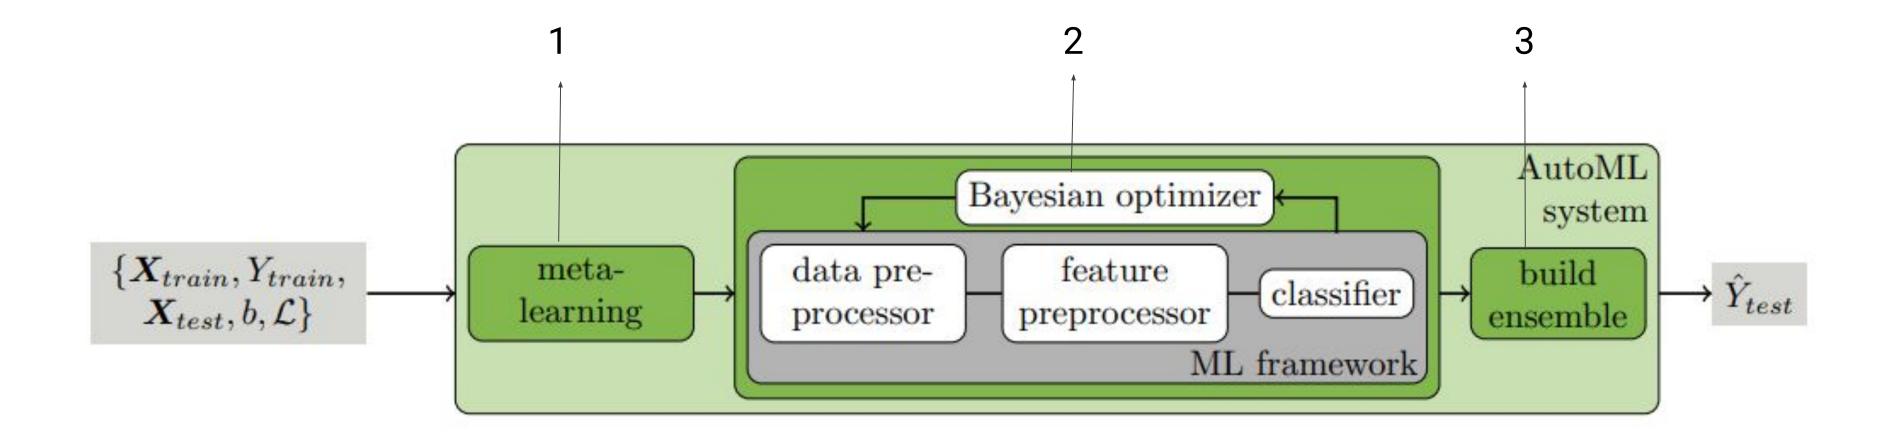
Classificadores:

- SVC
- LinearSVC
- KNeighborsClassifier
- RandomForestClassifier
- ExtraTreesClassifier
- SGDClassifier
- MultinomialNB
- BernoulliRBM
- ColumnKMeans

```
from hpsklearn import HyperoptEstimator, svc
estim = HyperoptEstimator(classifier=svc('mySVC'))
```

```
from hpsklearn import HyperoptEstimator, any_sparse_classifier, tfidf
from hyperopt import tpe
estim = HyperoptEstimator(classifier=any_sparse_classifier('clf'),
                          preprocessing=[tfidf('tfidf')],
                          algo=tpe.suggest, trial_timeout=300)
estim.fit(x_train, y_train)
print(estim.score(x_test, y_test))
print(estim.best_model())
```



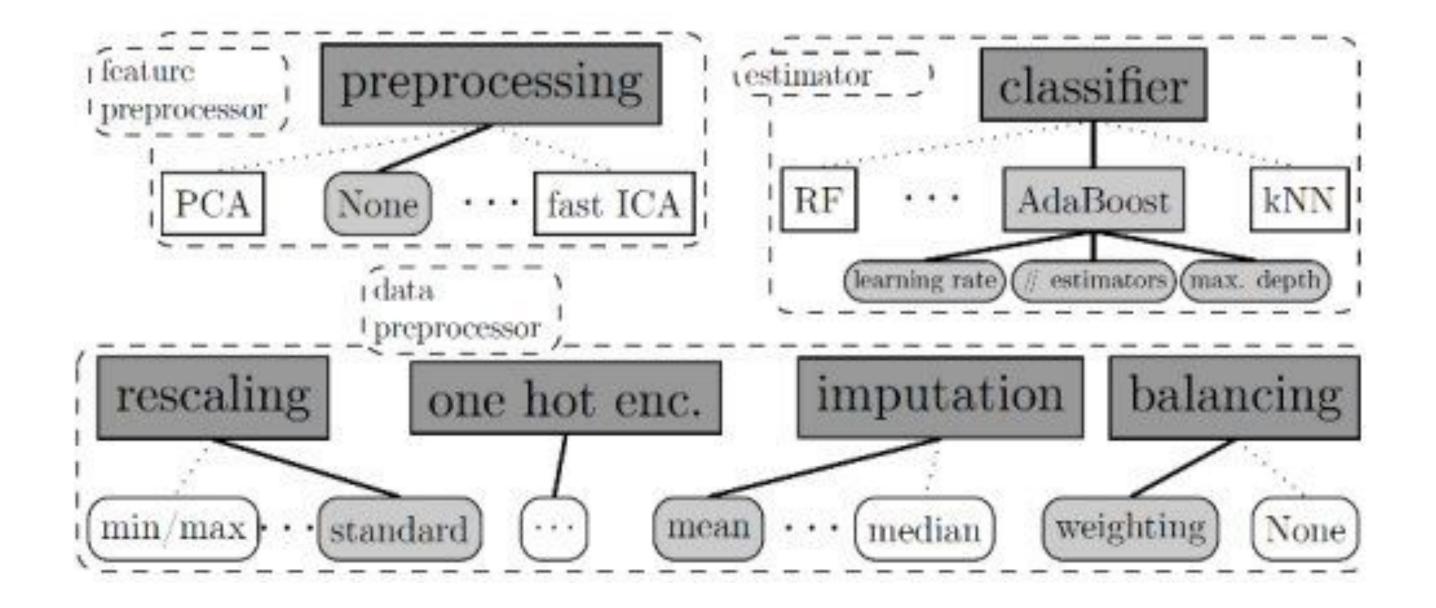


| name | $\#\lambda$ | cat (cond) | cont (cond) |
|-------------------------|-------------|------------|-------------|
| AdaBoost (AB) | 4 | 1 (-) | 3 (-) |
| Bernoulli naïve Bayes | 2 | 1 (-) | 1 (-) |
| decision tree (DT) | 4 | 1 (-) | 3 (-) |
| extreml. rand. trees | 5 | 2 (-) | 3 (-) |
| Gaussian naïve Bayes | - | - | - |
| gradient boosting (GB) | 6 | - | 6 (-) |
| kNN | 3 | 2 (-) | 1 (-) |
| LDA | 4 | 1 (-) | 3(1) |
| linear SVM | 4 | 2 (-) | 2 (-) |
| kernel SVM | 7 | 2 (-) | 5(2) |
| multinomial naïve Bayes | 2 | 1 (-) | 1 (-) |
| passive aggressive | 3 | 1 (-) | 2 (-) |
| QDA | 2 | 144 | 2 (-) |
| random forest (RF) | 5 | 2 (-) | 3 (-) |
| Linear Class. (SGD) | 10 | 4(-) | 6(3) |

(a) classification algorithms

| name | $\#\lambda$ | cat (cond) | cont (cond) |
|---------------------------|-------------|------------|-------------|
| extreml. rand. trees prep | r. 5 | 2 (-) | 3 (-) |
| fast ICA | 4 | 3 (-) | 1(1) |
| feature agglomeration | 4 | 3 () | 1 (-) |
| kernel PCA | 5 | 1 (-) | 4(3) |
| rand. kitchen sinks | 2 | - | 2 (-) |
| linear SVM prepr. | 3 | 1 (-) | 2 (-) |
| no preprocessing | - | - | - |
| nystroem sampler | 5 | 1 (-) | 4(3) |
| PCA | 2 | 1 (-) | 1 (-) |
| polynomial | 3 | 2 (-) | 1 (-) |
| random trees embed. | 4 | - | 4 (-) |
| select percentile | 2 | 1 (-) | 1 (-) |
| select rates | 3 | 2 (-) | 1 (-) |
| one-hot encoding | 2 | 1 (-) | 1(1) |
| imputation | 1 | 1 (-) | - |
| balancing | 1 | 1 (-) | - |
| rescaling | 1 | 1 (-) | - |

(b) preprocessing methods

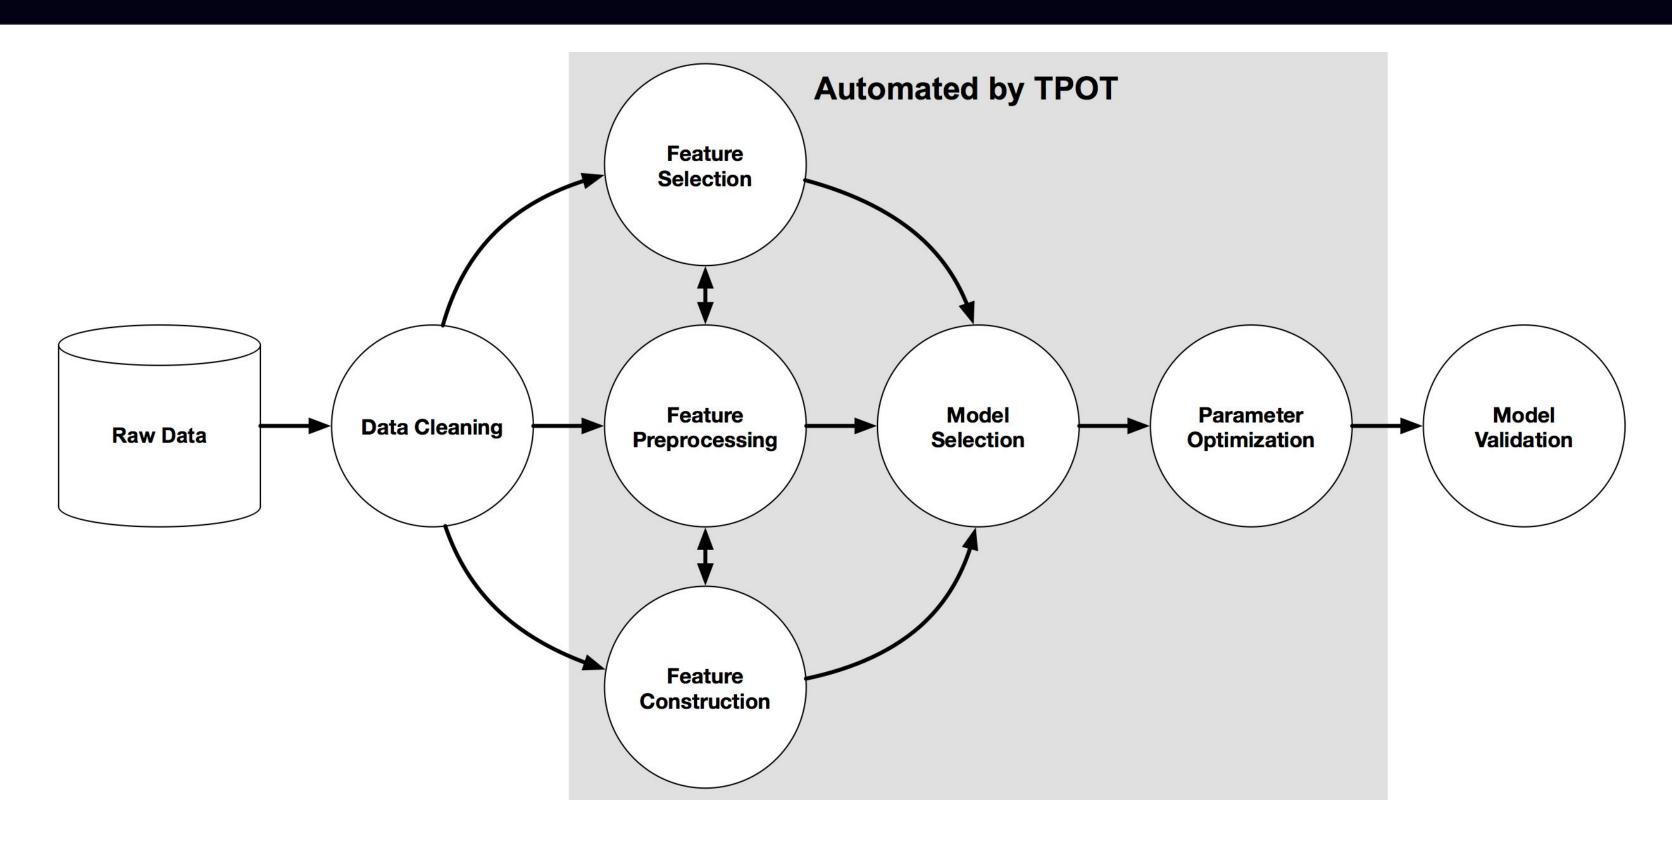


```
import autosklearn.classification
cls = autosklearn.classification.AutoSklearnClassifier()
cls.fit(X_train, y_train)
predictions = cls.predict(X_test)
```

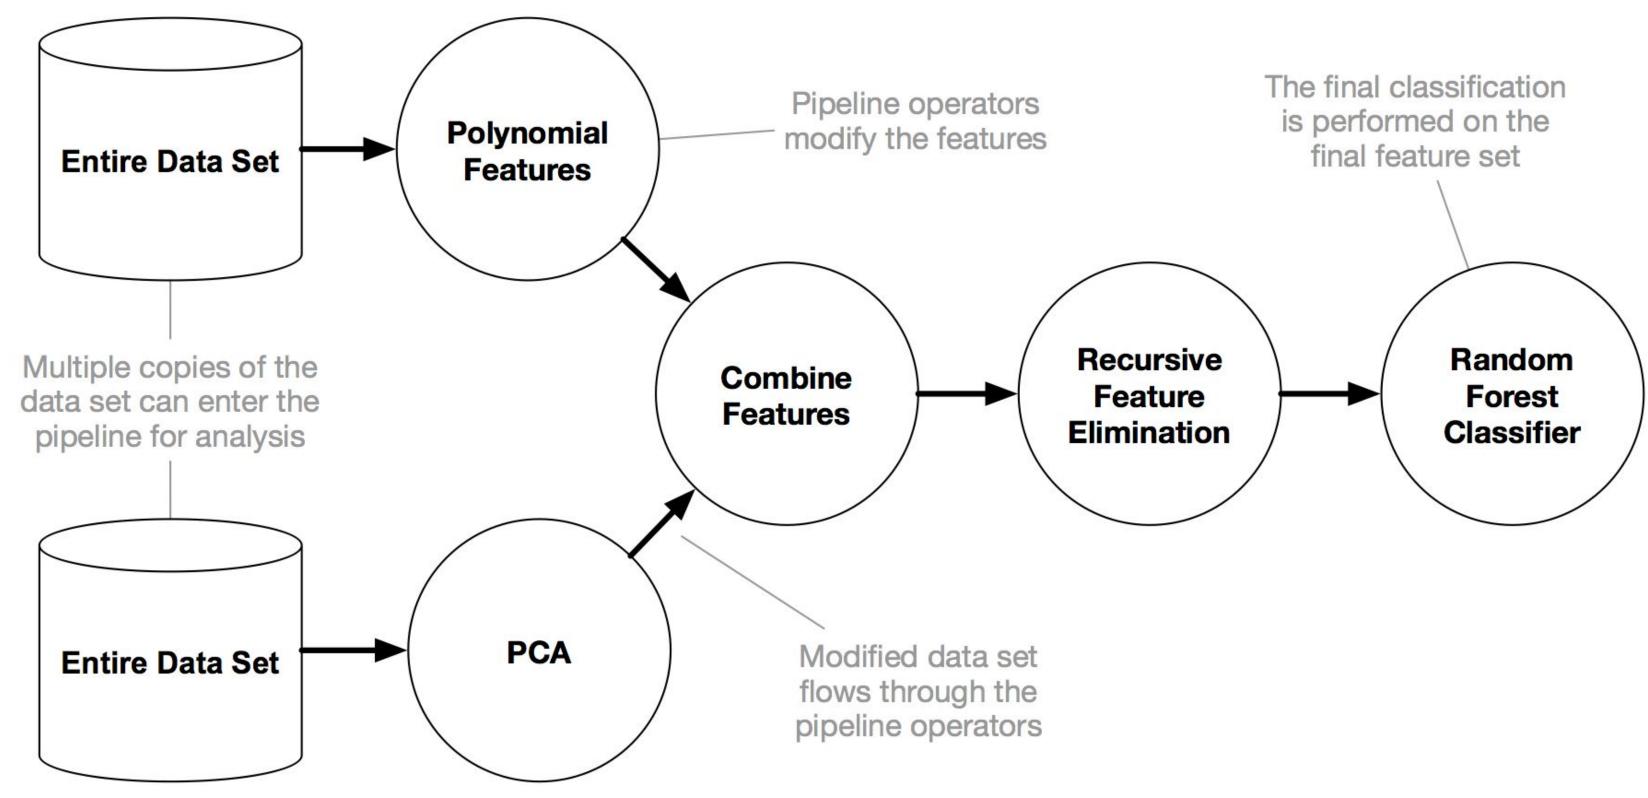
// Auto-Keras

```
import autokeras as ak
clf = ak.TextClassifier(max_trials=3)
clf.fit(x_train, y_train, epochs=2)
predicted_y = clf.predict(x_test)
print(clf.evaluate(x_test, y_test))
```

// TPOT



// TPOT



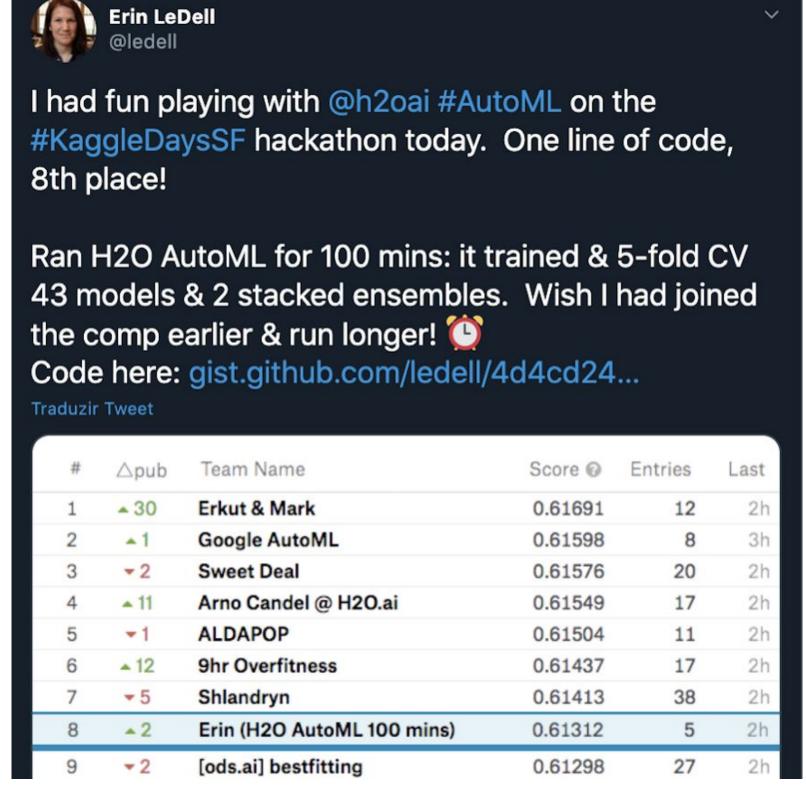
https://epistasislab.github.io/tpot/

// H2O AutoML



- H2O é uma biblioteca de ML escrita em Java que possui bibliotecas para uso em R e Python
- Busca trazer ML de forma escalável e facilitar o processo de deploy
- H2O AutoML é um módulo que inclui treinamento e tuning de diversos modelos dado um tempo limite especificado pelo usuário
- Busca aleatória seguida de criação de stacked ensembles

// H2O AutoML



http://docs.h2o.ai/h2o/latest-stable/h2o-docs/automl.html

// PyCaret



Data Preparation



Model Training



Hyperparameter Tuning



Analysis & Interpretability

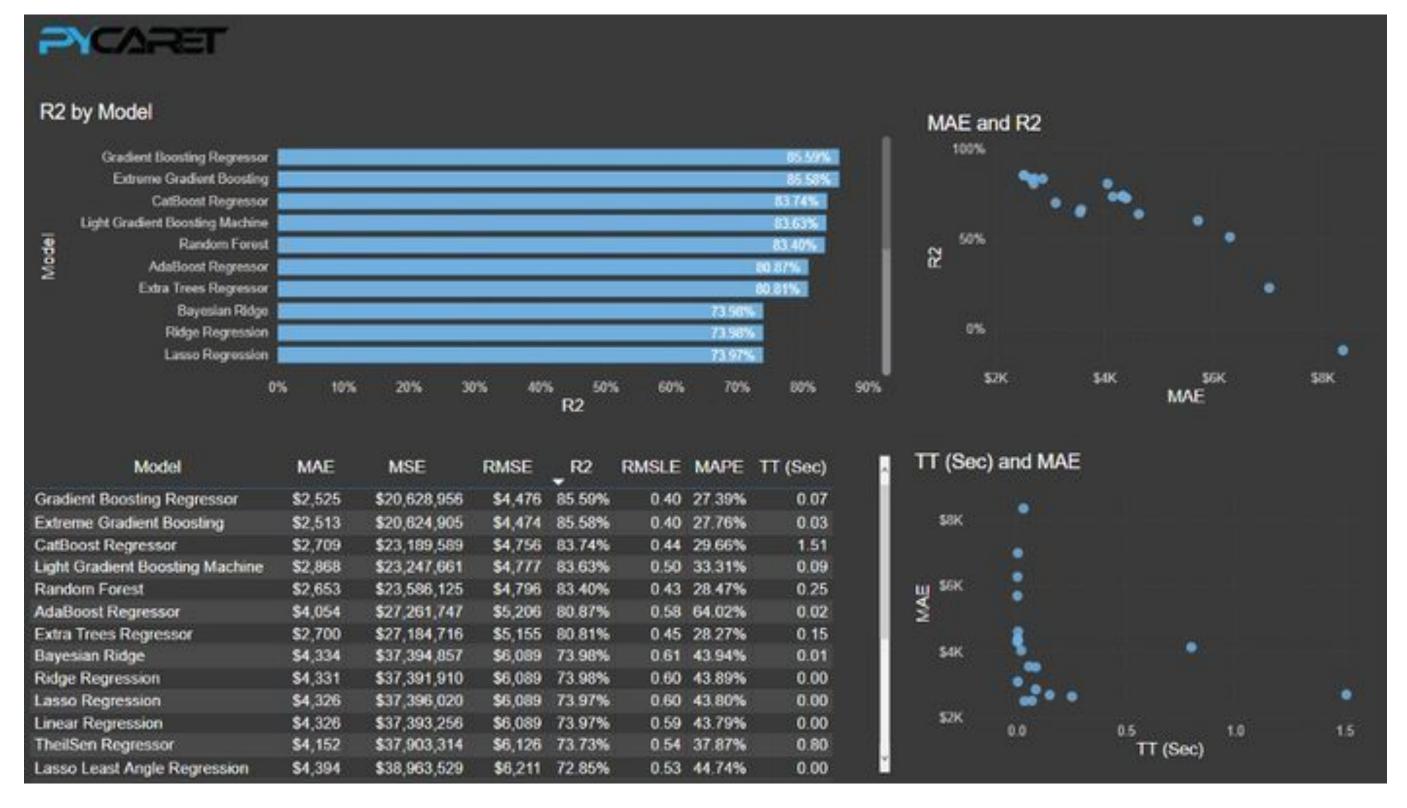


Model Selection



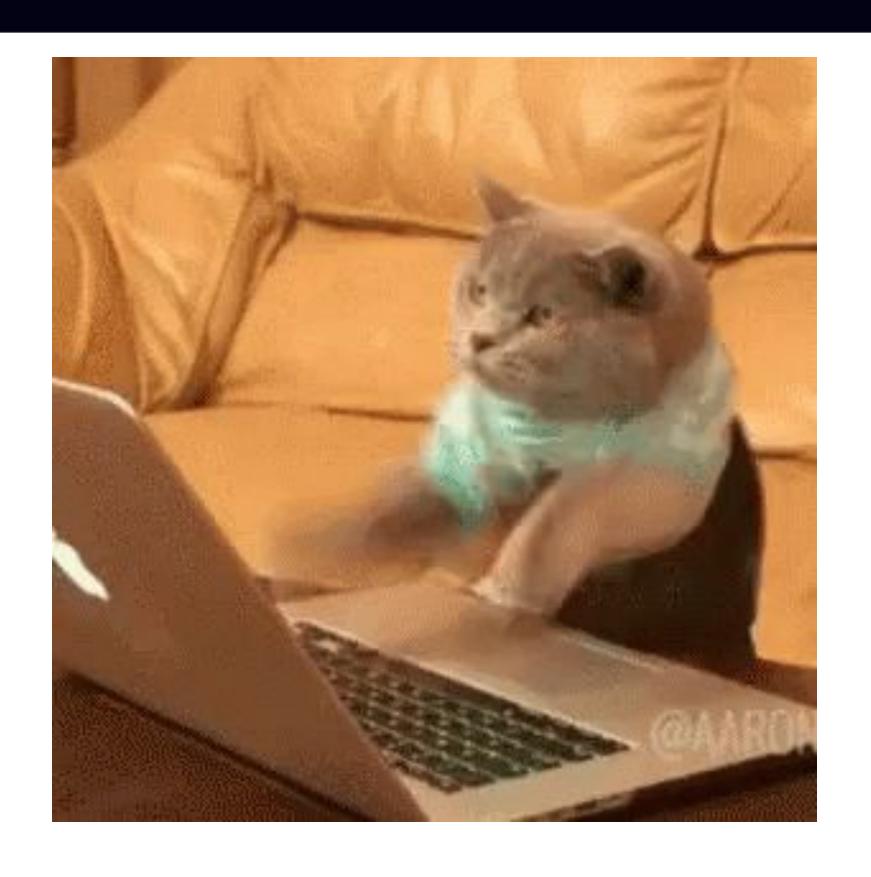
Experiment Logging

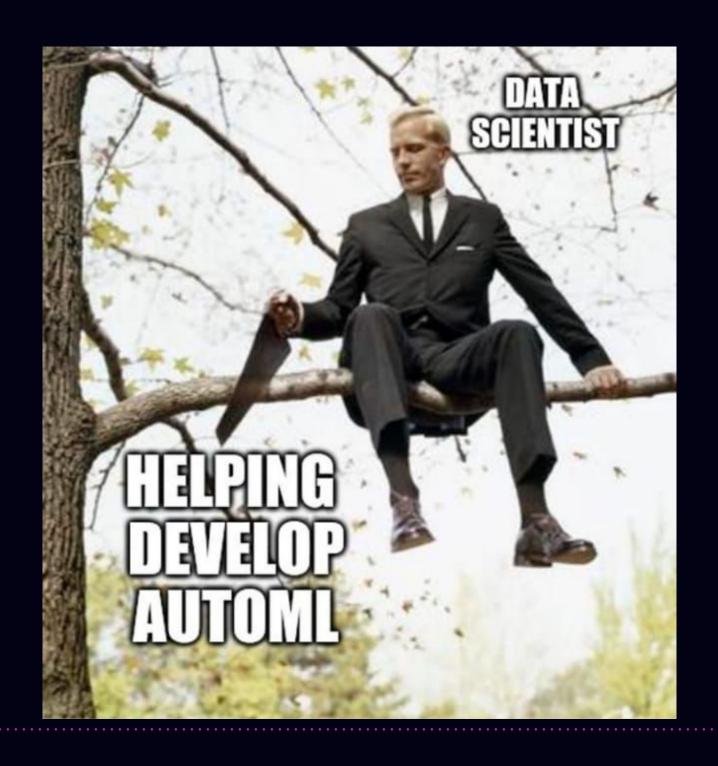
// PyCaret



https://www.kdnuggets.com/2020/08/build-automl-pycaret.html

// Show me the code

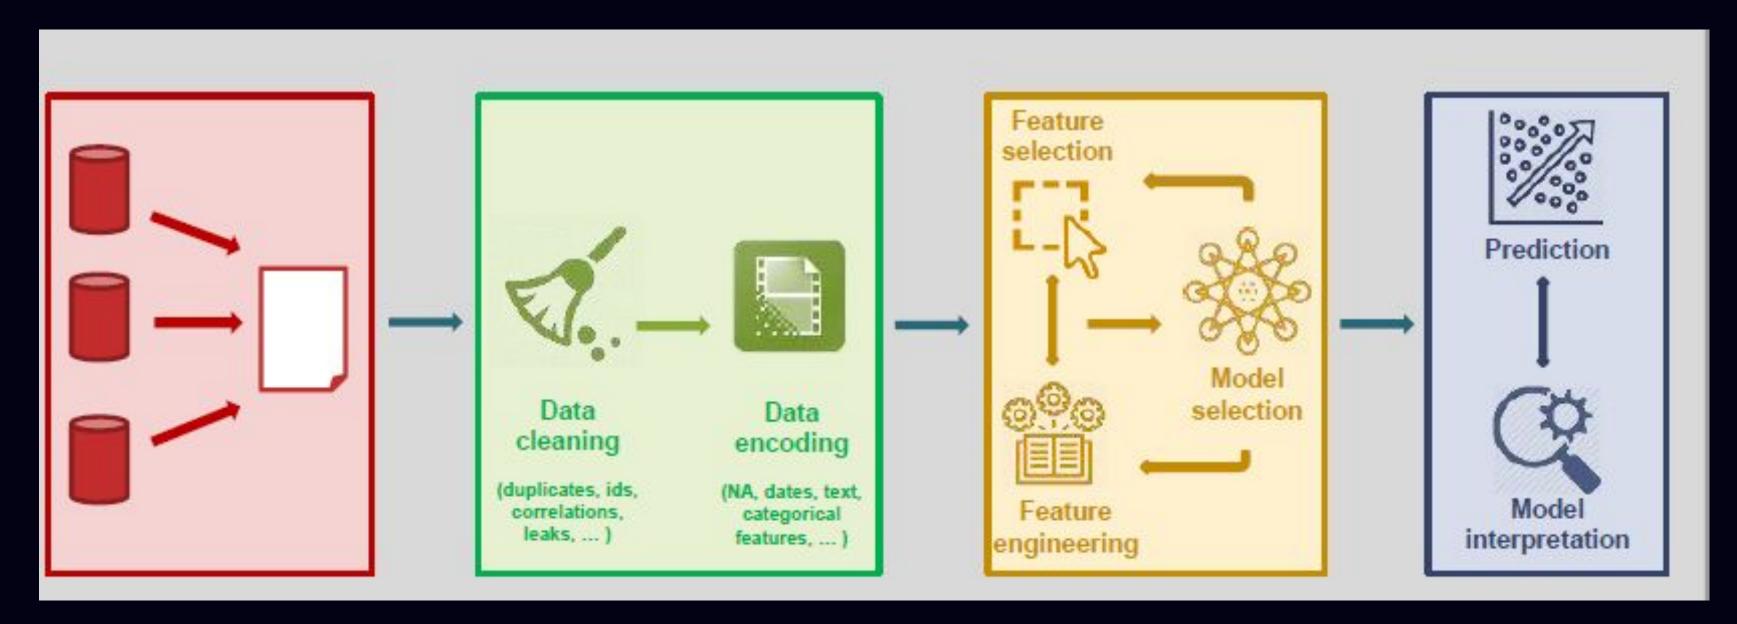




Limitações

- Não alcança o estado da arte em diversas tarefas, principalmente em relação a processamento de texto, imagens e voz.
- Problemas de transparência.
- Ainda não há implementações de AutoML para Sistemas de recomendação e Reinforcement learning.
- Não possui conhecimento de negócio

.....





Mario Filho • 1st

Lead Data Scientist | Machine Learning Expert | Kaggle Grandmaster

Mesmo com AutoML vale a pena entender como funcionam os algoritmos?

Sim.

Estou estudando o PyCaret que é uma lib fantástica, super promissora, mas até dia 28/10 (4 dias atrás) ela fazia pré-processamento antes do split (que vaza info da validação).

Não tenha medo da automação, mas sempre verifique os detalhes;)

E parabéns aos devs que corrigiram rapidamente!

#machinelearning #datascience #deeplearning #ai

See translation





♦ ② 296 • 10 Comments

// Referências

- Automated Machine Learning: Methods, Systems and Challenges -Frank Hutter, Lars Kotthoff e Joaquin Vanschoren
- Palestra "machine learning made easy(ish)" Leonardo Bezerra na Python Brasil [14]: https://www.youtube.com/watch?v=nuRDxYF_35A
- https://medium.com/data-hackers/automl-uma-nova-abordagem-de-machine-learning-87a40d866dc1
- https://medium.com/data-hackers/automated-machine-learning-automl
 -70c1eab669ad



OBRIGADO!